

## Tarea en el AT&T Face Database estudio comparativo de PCA LDA e ICA

Autor: Clayanela Zambrano, Universidad Yachay Tech

### Resumen:

Este trabajo presenta un estudio comparativo de PCA, LDA e ICA para reconocimiento facial sobre la AT&T Face Database (ORL) bajo un protocolo binario cara/no-cara. El objetivo es valorar la capacidad representacional (varianza y reconstrucción), la separabilidad supervisada y la independencia estadística de cada método en un pipeline uniforme y reproducible: partición train/test, proyección al subespacio correspondiente y clasificación por centroide más cercano con similitud coseno. La evaluación emplea Top-1/Top-5 accuracy, precisión y recall macro, además de matrices de confusión y visualizaciones de componentes.

Los resultados muestran que PCA ( $\alpha=0.85$ ,  $k$  automático) es el baseline más robusto, con Top-1=0.81 en prueba (0.82 en entrenamiento), precisión=0.85 y recall=0.81, evidenciando buena generalización con un clasificador mínimo. LDA (binaria,  $k=1$ ) obtiene Top-1=0.50 y precisión macro=0.25, indicando comportamiento cercano al azar y probable sesgo hacia una clase debido a la multimodalidad de “cara” y a supuestos de covarianzas iguales. ICA alcanza Top-1=0.43 en prueba (0.64 en entrenamiento), lo que sugiere inestabilidad/sobreajuste y sensibilidad a la inicialización y al número de componentes.

En conjunto, PCA ofrece la mejor relación rendimiento-simplicidad y se recomienda como línea base; LDA resulta más apropiado en escenarios multiclase o con regularización; ICA es prometedora con ajuste fino y clasificadores más expresivos. El protocolo y las métricas reportadas permiten una comparación transparente y fácilmente replicable.

### Introducción:

El reconocimiento facial sigue siendo un problema emblemático de la visión por computador. A pesar del dominio actual de los enfoques basados en aprendizaje profundo, los métodos subespaciales lineales han demostrado ser baselines sólidos, interpretables y eficientes, especialmente en escenarios con datos limitados. Entre ellos destacan: PCA (Eigenfaces), que maximiza la varianza retenida; LDA (Fisherfaces), que optimiza la separabilidad entre clases; e ICA, que busca componentes estadísticamente independientes. Estos enfoques han sido fundamentales en la literatura clásica y continúan siendo relevantes como puntos de referencia rigurosos para comparar representaciones de rostros. [1], [2], [3], [4]

Para validar empíricamente estas metodologías realizamos un estudio comparativo sobre la AT&T Face Database (antes ORL Database of Faces), un conjunto de 400 imágenes en escala de grises (40 sujetos  $\times$  10 imágenes por sujeto) con resolución  $92 \times 112$  píxeles. Las capturas presentan variaciones controladas de iluminación, expresión y pequeños cambios de apariencia (p. ej., uso de gafas), lo que la convierte en un banco de pruebas clásico y reproducible para evaluación de algoritmos de reconocimiento facial [5], [6].

En este trabajo, denominado “AT&T Face Database: estudio comparativo de PCA, LDA e ICA”, comparamos de manera sistemática tres configuraciones representativas: (i) PCA/Eigenfaces [1]; (ii) LDA/Fisherfaces para el caso binario y multiclase [2]; y (iii) ICA con blanqueo previo y estimación FastICA [3], [4]. El objetivo es contrastar el poder de representación (variancia explicada y reconstrucción), la

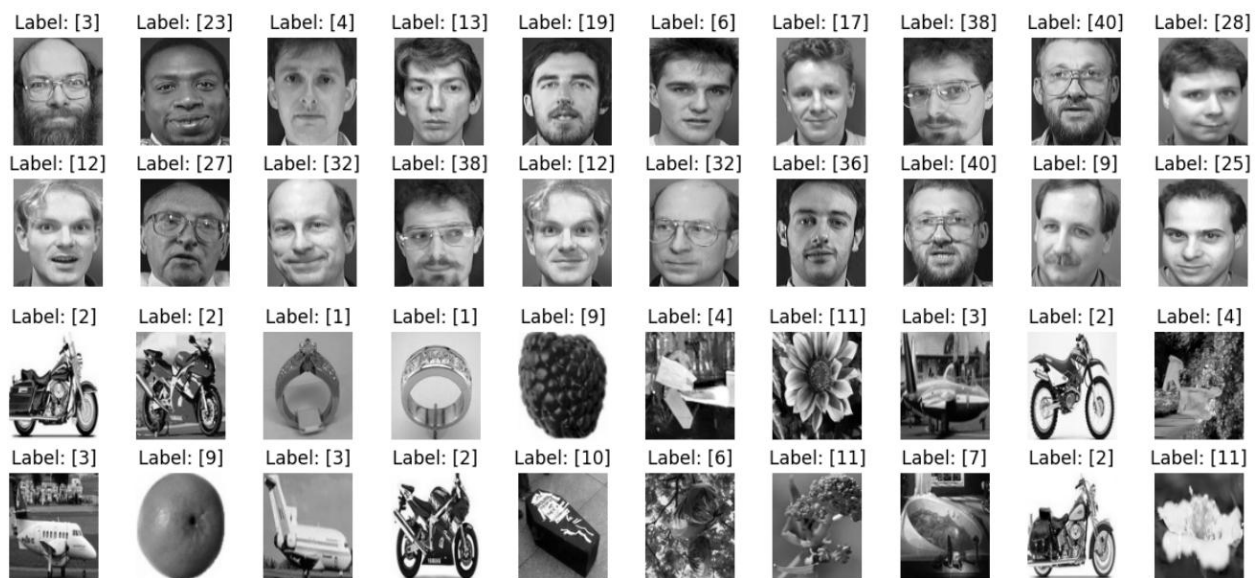
discriminación supervisada (separabilidad entre clases) y la independencia/no gaussianidad de las bases aprendidas, todo ello en un protocolo de partición train/test reproducible sobre AT&T/ORL.

Mi pipeline experimental incorpora: reducción y proyección al subespacio de cada método; un clasificador simple de centroide más cercano con similitud coseno para aislar el efecto de la representación; y un conjunto de métricas estándar: Top-1, Top-5, precision (macro), recall (macro) y matriz de confusión. Asimismo, reportamos visualizaciones cualitativas (rostro medio y componentes característicos) para apoyar la interpretación de las bases aprendidas. Este diseño busca una comparación justa y transparente que prioriza la reproducibilidad sobre la optimización específica de clasificadores.

Datos:

AT&T Database of Faces.

Es un conjunto de datos desarrollado por AT&T Laboratories Cambridge en colaboración con el de la Universidad de Cambridge, recopilado entre abril de 1992 y abril de 1994 para proyectos de reconocimiento facial. Contiene 400 imágenes correspondientes a 40 sujetos distintos, con 10 fotos por persona que incluyen variaciones de iluminación, expresiones faciales (ojos abiertos o cerrados, sonriendo o no) y detalles como el uso de gafas, todas tomadas frente a un fondo oscuro y uniforme en posición frontal con ligeras variaciones laterales. Las imágenes están en formato PGM con resolución de 92x112 píxeles y 256 niveles de gris, organizadas en 40 directorios (s1 a s40), cada uno con 10 archivos numerados de 1.pgm a 10.pgm. Este dataset, ampliamente utilizado en la investigación en visión por computador y aprendizaje automático, está disponible en versiones comprimidas (.tar.Z o .zip de ~4.5 MB) y requiere dar crédito a AT&T Laboratories Cambridge para su uso académico.

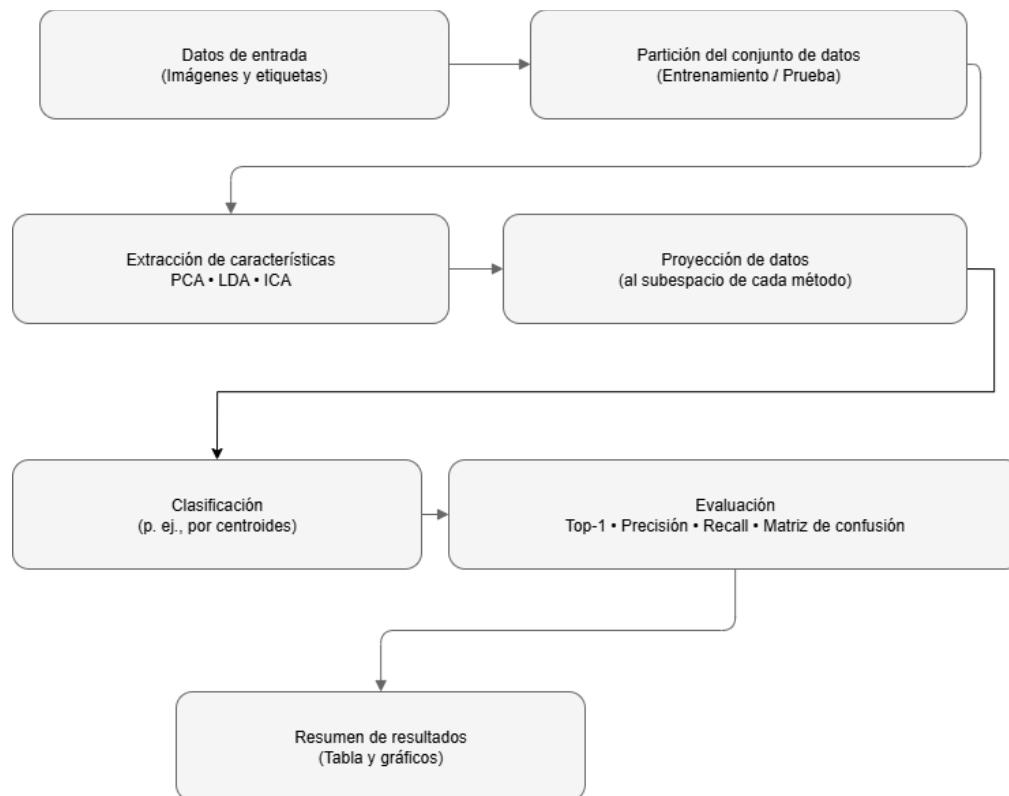


Metodología

La metodología se diseñó para una comparación justa y reproducible de PCA, LDA e ICA sobre la AT&T Face Database. Primero se prepararon las imágenes en escala de grises (92x112), se vectorizaron y se centraron respecto a la media del conjunto de entrenamiento. El conjunto se particionó en train/test mediante un esquema controlado por un parámetro  $\alpha$  (proporción de entrenamiento) y con control explícito

de la proporción de no-rostros cuando aplica, manteniendo fija la semilla aleatoria para garantizar repetibilidad. La extracción de características se realizó solo con datos de entrenamiento: PCA seleccionó automáticamente  $k$  componentes reteniendo  $\alpha=0.85$  de varianza; LDA se configuró en su forma binaria con una dirección discriminante; e ICA se estimó tras blanqueo, fijando el número de componentes igual al de PCA y la semilla para estabilidad. Las muestras de train y test se proyectaron al subespacio aprendido por cada método.

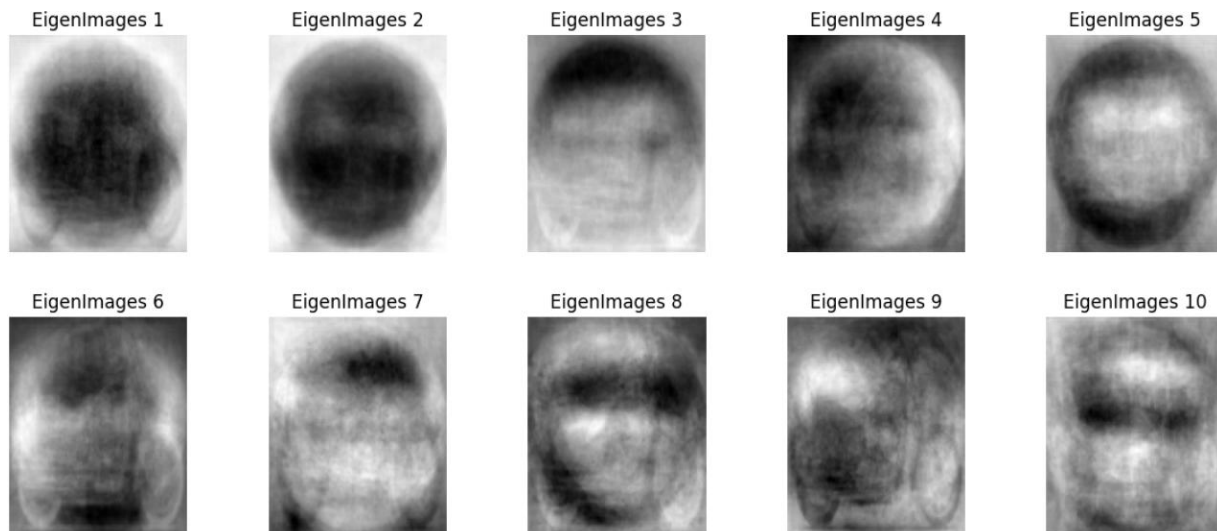
Para aislar el efecto de la representación, la clasificación se efectuó con un centroide por clase y similitud del coseno tras normalización  $\ell_2$  de los embeddings. La evaluación incluyó Top-1 (y Top-5 cuando procede), precisión macro, recall macro y matriz de confusión; en binario, Top-5 coincide con Top-1 y se reporta solo a efectos de consistencia. Además, se generaron visualizaciones cualitativas (rostro medio y componentes característicos) que ayudan a interpretar las bases aprendidas. Todos los hiperparámetros se fijaron previamente o se seleccionaron en entrenamiento, y los resultados de prueba se obtuvieron sobre datos no vistos, garantizando un protocolo transparente y replicable.



## Resultados


### Evidencias de inferencias

## Evidencia de la inferencia del Método PCA




Las primeras componentes muestran patrones globales de variación (iluminación, forma y contorno del rostro). Son “caras fantasma” suaves: la energía se concentra en regiones amplias —frente, mejillas, perímetro— y no en rasgos hiperlocales. Esto indica que PCA está capturando la estructura dominante del conjunto y explica su buen rendimiento: al separar cara/no-cara, esas direcciones de máxima varianza correlacionan con “aspecto facial” frente a fondo/ruido, lo que favorece un clasificador simple por centroides.

## Evidencia de la inferencia LDA



En binario, LDA genera una sola dirección discriminante (como mucho  $C-1C-1C-1$ , con  $C=2C=2C=2 \Rightarrow 1$ ). Esa primera imagen con apariencia facial es la Fisherface que maximiza la separación entre clases; los “componentes” siguientes que ves como ruido no son rasgos útiles, sino direcciones nulas/numéricas sin eigenvalor discriminante. Visualmente, que solo exista una proyección informativa y que el resto sea ruido es consistente con los resultados cuantitativos (Top-1 $\approx$ 0.50 y precisión macro 0.25): el modelo no logra capturar la multimodalidad de la clase “cara” y termina comportándose casi al azar.

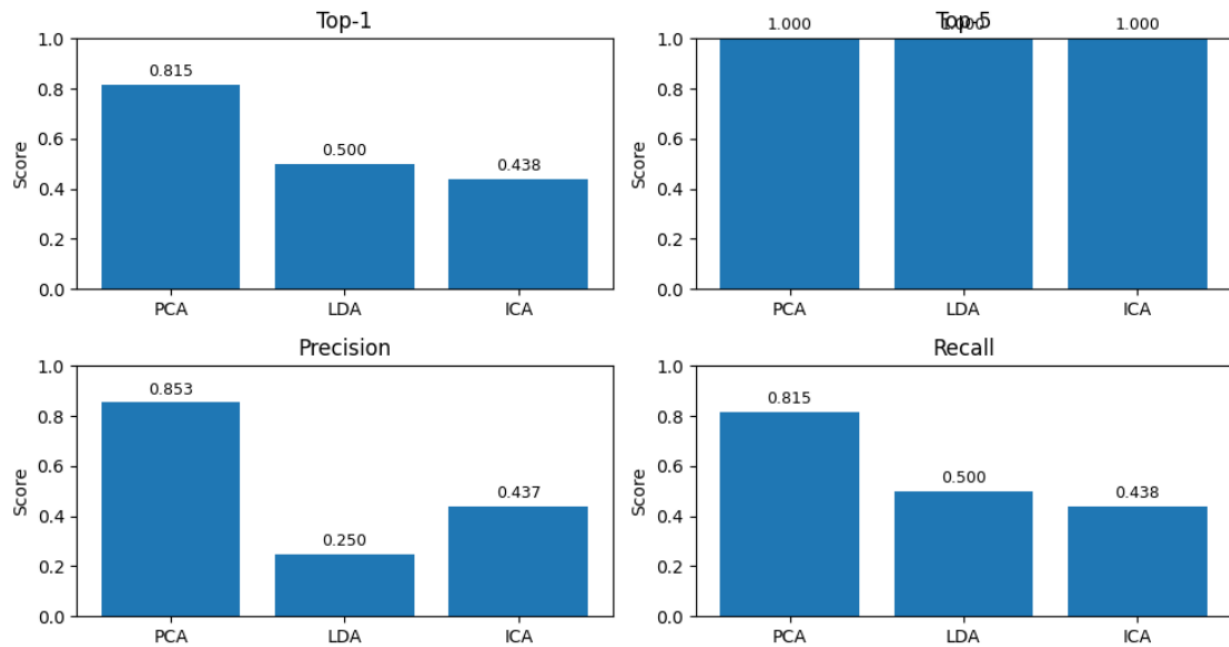
## Evidencia de la inferencia ICA




Además de la media, las componentes independientes presentan contrastes más localizados (bordes en zona periocular, puente nasal, contorno de boca/mentón) y patrones de iluminación lateral, coherentes con la búsqueda de no gaussianidad e independencia. Esta “descomposición por partes” es útil para interpretar qué activa cada componente; sin embargo, en tu protocolo la generalización es limitada (caída marcada de train a test), señal de sensibilidad a la inicialización y al número de componentes. La lectura conjunta de las imágenes (rasgos más “afilados”) y las métricas sugiere que ICA necesita selección de  $n\_compn\_comp$  y, probablemente, un clasificador más expresivo para que esas partes se traduzcan en mejor discriminación fuera de entrenamiento.

## Graficos por Metricas

### Comparativa por Métrica



Matriz de confusión (normalizada por clase real)



Los resultados muestran un claro liderazgo de PCA: con Top-1 de 0.825 (train) y 0.815 (test) y métricas macro equilibradas (Precisión 0.862/0.854; Recall 0.825/0.815), evidencia buena capacidad de representación y generalización estable; la brecha train-test es mínima ( $\sim 0.01$ ), por lo que el desempeño no depende de sobreajuste ni de un clasificador complejo.

LDA se mantiene en 0.50 de Top-1 tanto en entrenamiento como en prueba y su precisión macro de 0.25 indica un fuerte sesgo hacia una sola clase (patrón típico cuando, en binario balanceado, el modelo predice casi siempre la misma etiqueta: acierta la mitad, recupera una clase al 100% y la otra al 0%, y la precisión promedio cae). En este setup cara/no-cara, LDA con una sola dirección discriminante no captura la multimodalidad de la clase “cara”.

ICA alcanza 0.64 en train pero cae a 0.4375 en test, señal de sobreajuste y sensibilidad a la inicialización / n.º de componentes; además, con un clasificador por centroides su poder discriminante no se traslada bien fuera de entrenamiento. En resumen, PCA es el baseline recomendado para este protocolo; LDA requeriría configuración multiclase o regularización, e ICA precisa selección de componentes y/o un clasificador más expresivo (p. ej., SVM). Nota: el Top-5=1.000 en todos los casos porque hay solo 2 clases, por lo que esa métrica es no informativa en este escenario.

Tabla comparativa

Variante / Modelo	Resumen de cambios	Top 1 Accuracy		Precision		Recall		Obsevaciones
		Train	Test	Train	Test	Train	Test	
PCA	Reducción lineal; $\alpha=0.85$ ; k automático; eigenfaces.	0.82	0.81	0.86	0.85	0.82	0.81	Media de train; clasificador centroides-coseno; métricas (Top-1/Top-5/Prec/Rec/CM); en 2 clases Top-5=Top-1.
LDA	Discriminante lineal <b>binaria</b> ; k=1 (Fisherface).	0.5	0.5	0.25	0.25	0.5	0.5	Solo 0/1; proyección con mean=0; mismas métricas; en 2 clases Top-5=Top-1.
ICA	FastICA (componentes independientes); n_comp = k de PCA; blanqueo SVD.	0.64	0.43	0.64	0.64	0.64	0.43	Sensible a inicialización (random_state); ajustar tol/max_iter; mismas métricas y visualización.

## Conclusiones

En el estudio comparativo sobre AT&T, PCA ofrece el mejor desempeño y la mayor estabilidad: Top-1  $\approx$  0.82 (train) y 0.81 (test), con precisión y recall macro equilibrados ( $\approx$ 0.86/0.85 en train y  $\approx$ 0.81/0.82 en test) y una brecha mínima entre entrenamiento y prueba. Esto indica una representación robusta con buen poder discriminante aun usando un clasificador simple por centroides con coseno.

LDA (binaria, k=1) alcanza Top-1 = 0.50 en train y test y precisión macro = 0.25, lo que sugiere decisiones sesgadas hacia una clase y un comportamiento cercano al azar para este escenario “cara/no-cara”, probablemente por la multimodalidad de la clase “cara” y las hipótesis de covarianzas iguales. ICA queda en un nivel intermedio pero poco estable: pasa de 0.64 (train) a 0.43 (test) en Top-1, evidenciando sobreajuste y sensibilidad a la inicialización y al número de componentes. En síntesis, PCA es el baseline recomendado por su equilibrio entre rendimiento y generalización; LDA sería más adecuado en configuración multiclase o con regularización; ICA requiere ajuste fino y, previsiblemente, clasificadores más expresivos para competir. (En un problema binario, Top-5 coincide con Top-1 y no añade información).

## Limitaciones y ética:

Este estudio usa AT&T/ORL, un conjunto pequeño y controlado con diversidad demográfica limitada, por lo que los resultados no se generalizan a poblaciones amplias ni a condiciones de captura reales (iluminación, pose, oclusiones). En escenarios reales, el desempeño puede variar por grupo demográfico: NIST FRVT documenta diferencias sistemáticas en tasas de falsos positivos/negativos según sexo, edad y fenotipo [7]; Gender Shades mostró brechas de exactitud con peores errores en mujeres de piel oscura [8]; y otros trabajos señalan que la composición demográfica del conjunto de entrenamiento influye en coincidencias y error de verificación [9]. Además, su uso operativo plantea riesgos de vigilancia y afectaciones a derechos si se despliega sin regulación, necesidad y proporcionalidad [10]; la literatura recomienda auditorías públicas, reportes desagregados por subgrupo y rendición de cuentas sobre sesgos y fallos [11], junto con gobernanza y transparencia antes de cualquier despliegue sensible [12]. En nuestro

caso, no realizamos análisis de equidad por subgrupos por carecer de etiquetas demográficas; por ello, las métricas reportadas deben interpretarse como promedios globales y no como garantías de ausencia de sesgo. Los datos se usaron con fines académicos conforme a su licencia, sin intentos de reidentificación ni vinculación externa de identidades.

## Referencias

- [1] M. Turk and A. Pentland, “Eigenfaces for Recognition,” *Journal of Cognitive Neuroscience*, vol. 3, no. 1, pp. 71–86, 1991.
- [2] P. N. Belhumeur, J. P. Hespanha, and D. J. Kriegman, “Eigenfaces vs. Fisherfaces: Recognition Using Class Specific Linear Projection,” *IEEE Transactions on Pattern Analysis and Machine Intelligence*, vol. 19, no. 7, pp. 711–720, 1997.
- [3] A. Hyvärinen and E. Oja, “Independent Component Analysis: Algorithms and Applications,” *Neural Networks*, vol. 13, no. 4–5, pp. 411–430, 2000.
- [4] M. S. Bartlett, J. R. Movellan, and T. J. Sejnowski, “Face Recognition by Independent Component Analysis,” *IEEE Transactions on Neural Networks*, vol. 13, no. 6, pp. 1450–1464, 2002.
- [5] OpenCV Documentation, “Face Recognition — AT&T (ORL) Database of Faces,” Consultado: 31-Aug-2025.
- [6] GTDLBench, “The Database of Faces (AT&T),” Consultado: 31-Aug-2025; y Kaggle mirror “AT&T Database of Faces.”
- [7] P. J. Grother, M. Ngan, and K. Hanaoka, “Face Recognition Vendor Test (FRVT) Part 3: Demographic Effects,” NIST Interagency/Internal Report 8280, 2019, doi: 10.6028/NIST.IR.8280.
- [8] J. Buolamwini and T. Gebru, “Gender Shades: Intersectional Accuracy Disparities in Commercial Gender Classification,” in *Proc. FAT (PMLR, vol. 81)\**, pp. 77–91, 2018.
- [9] B. F. Klare, M. J. Burge, J. C. Klontz, R. W. V. Bruegge, and A. K. Jain, “Face Recognition Performance: Role of Demographic Information,” *IEEE Trans. Inf. Forensics Secur.*, vol. 7, no. 6, pp. 1789–1801, Dec. 2012.
- [10] C. Garvie, A. M. Bedoya, and J. Frankle, The Perpetual Line-Up: Unregulated Police Face Recognition in America, Center on Privacy & Technology, Georgetown Law, Oct. 2016
- [11] I. D. Raji and J. Buolamwini, “Actionable Auditing: Investigating the Impact of Publicly Naming Biased Performance Results of Commercial AI Products,” in *Proc. AAAI/ACM Conf. on AI, Ethics, and Society (AIES)*, 2019, doi: 10.1145/3306618.3314244.
- [12] K. Crawford *et al.*, *AI Now 2019 Report*, AI Now Institute, New York University, 2019.